



פרויקט גמר בינה עסקית

חזוי ביטולים ושיפור רוחיות במלון

15.6.2024



חברי הקבוצה

עדן פבריקנט

סטודנט למדעי הנתונים

יאמן סלאלחה

סטודנט להנדסה תעשייה וניהול

יעל אברהם

סטודנטית למדעי הנתונים



הקדמה



הפרויקט שלנו עוסק בניתוח נתוני הזמנות של מלון, שנלקחו ממאגר Kaggle, במטרה לזהות את הגורמים המשפיעים על ביטולים, להבין אילו לקוחות נוטים לבטל, וכיצד ניתן לחזות ולהפחית את שיעור הביטולים. באמצעות כלים של בינה עסקית ואלגוריתמים של כריית מידע, ביצענו ניתוחים שהובילו להפקת תובנות עסקיות, חיזוי התנהגות לקוחות, והצעת אסטרטגיות ממוקדות לשימור ושיפור הרווחיות.



השאלה המחקרית



מהם הגורמים המרכזיים שמשפיעים על ביטול הזמנות במלון ?
כיצד ניתן לחזות מראש הזמנות בסיכון גבוה לביטול ?
ואיך ניתן להשתמש במידע הזה כדי :
לשפר את שימור הלקוחות
למשוך לקוחות רווחיים יותר
ולהגדיל את הרווח הכולל של המלון



המטרות



הגדלת רווחיות

הפקת תובנות עסקיות למקסום הכנסה
וייעול תהליכים



שימור לקוחות

זיהוי לקוחות נאמנים
והצעת אסטרטגיות שימור מותאמות



משיכת לקוחות רווחיים

פילוח לקוחות לפי ערך כלכלי
והתאמת הצעות ייחודיות



חיזוי ביטולים

ניתוח מאפייני הזמנה
ולקוח לזיהוי סיכון גבוה לביטול

על מאגר הנתונים

השתמשנו במאגר נתונים שנלקח מאתר Kaggle, המתאר הזמנות של שני מלונות בפורטוגל (מלון עירוני ומלון נופש). המאגר כולל כ־120 אלף רשומות ו־32 עמודות, עם פרטים שונים על תהליך ההזמנה, הלקוח, סוג החדר, סטטוס ההזמנה ועוד. במהלך העבודה ניתחנו את הנתונים והפקנו תובנות עסקיות שמטרתן לשפר את שימור הלקוחות, להפחית ביטולים ולהגדיל את רווחי המלון.

JESSE MOSTIPAK · UPDATED 5 YEARS AGO

▲

Hotel booking demand

From the paper: hotel booking demand datasets

- Data Card
- Code (562)
- Discussion (28)
- Suggestions (0)

About Dataset

Context

Have you ever wondered when the best time of year to book a hotel room is? Or how long to stay in order to get the best daily rate? What if you wanted to predict whether a guest is likely to receive a disproportionately high number of special requests?

This hotel booking dataset can help you explore those questions!



תהליך ETL - ניקוי והכנת נתונים

```
# שלב 1: טעינת הנתונים (Extract + Load)
file_path = "Data/hotel_bookings.csv"
df = pd.read_csv(file_path)

# שלב 2: ניקוי נתונים (Cleaning)

# מחיקת עמודת company (כי רוב הערכים חסרים)
df.drop(columns=['company'], inplace=True)

# הזמנה ישירות מהמלון - agent 0
# מילוי ערכים חסרים ב-agent
df['agent'] = df['agent'].fillna(0).astype(int)


# מילוי ערכים חסרים ב-children
df['children'] = df['children'].fillna(0)

# מילוי ערכים חסרים ב-country
most_common_country = df['country'].mode()[0]
df['country'] = df['country'].fillna(most_common_country)
```



שלבים
- Extract

טעינת הנתונים מקובץ CSV מתוך Kaggle



- Transform

- הסרת עמודות לא רלוונטיות

- השלמת ערכים חסרים

- המרת טיפוסים

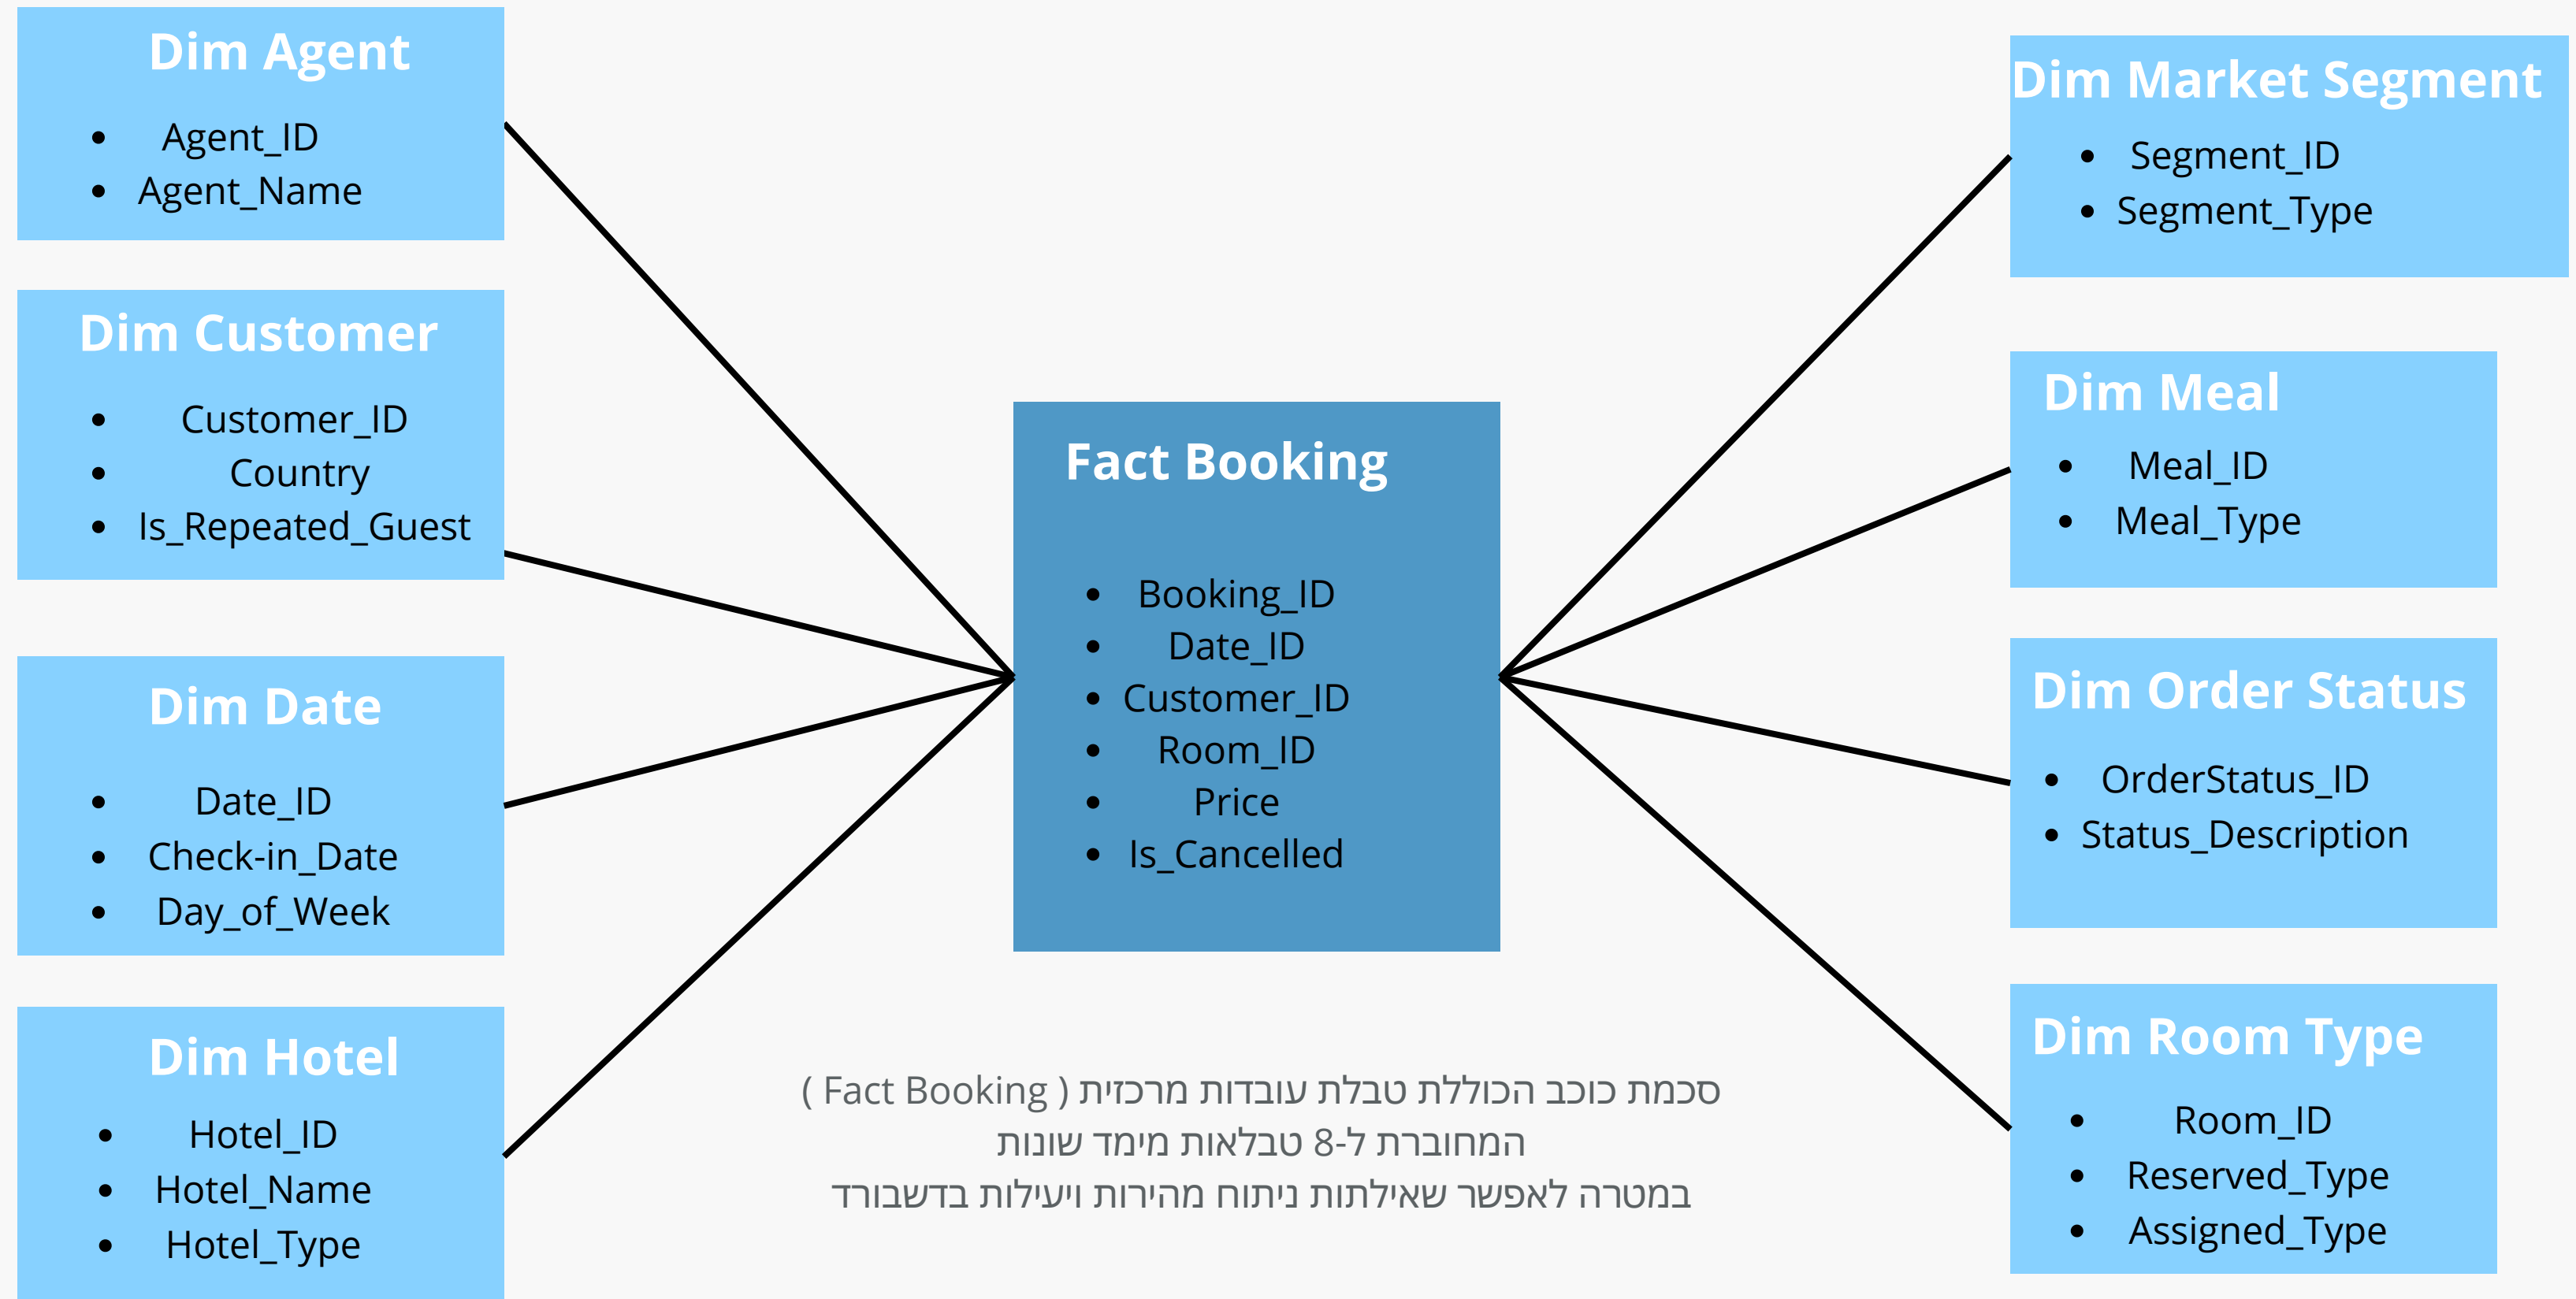
- אחידות בשמות קטגוריות



- Load

ייצוא לקובץ CSV נקי להמשך השימוש


מחסן הנתונים - סכמת כוכב



כלי BI - Tableau



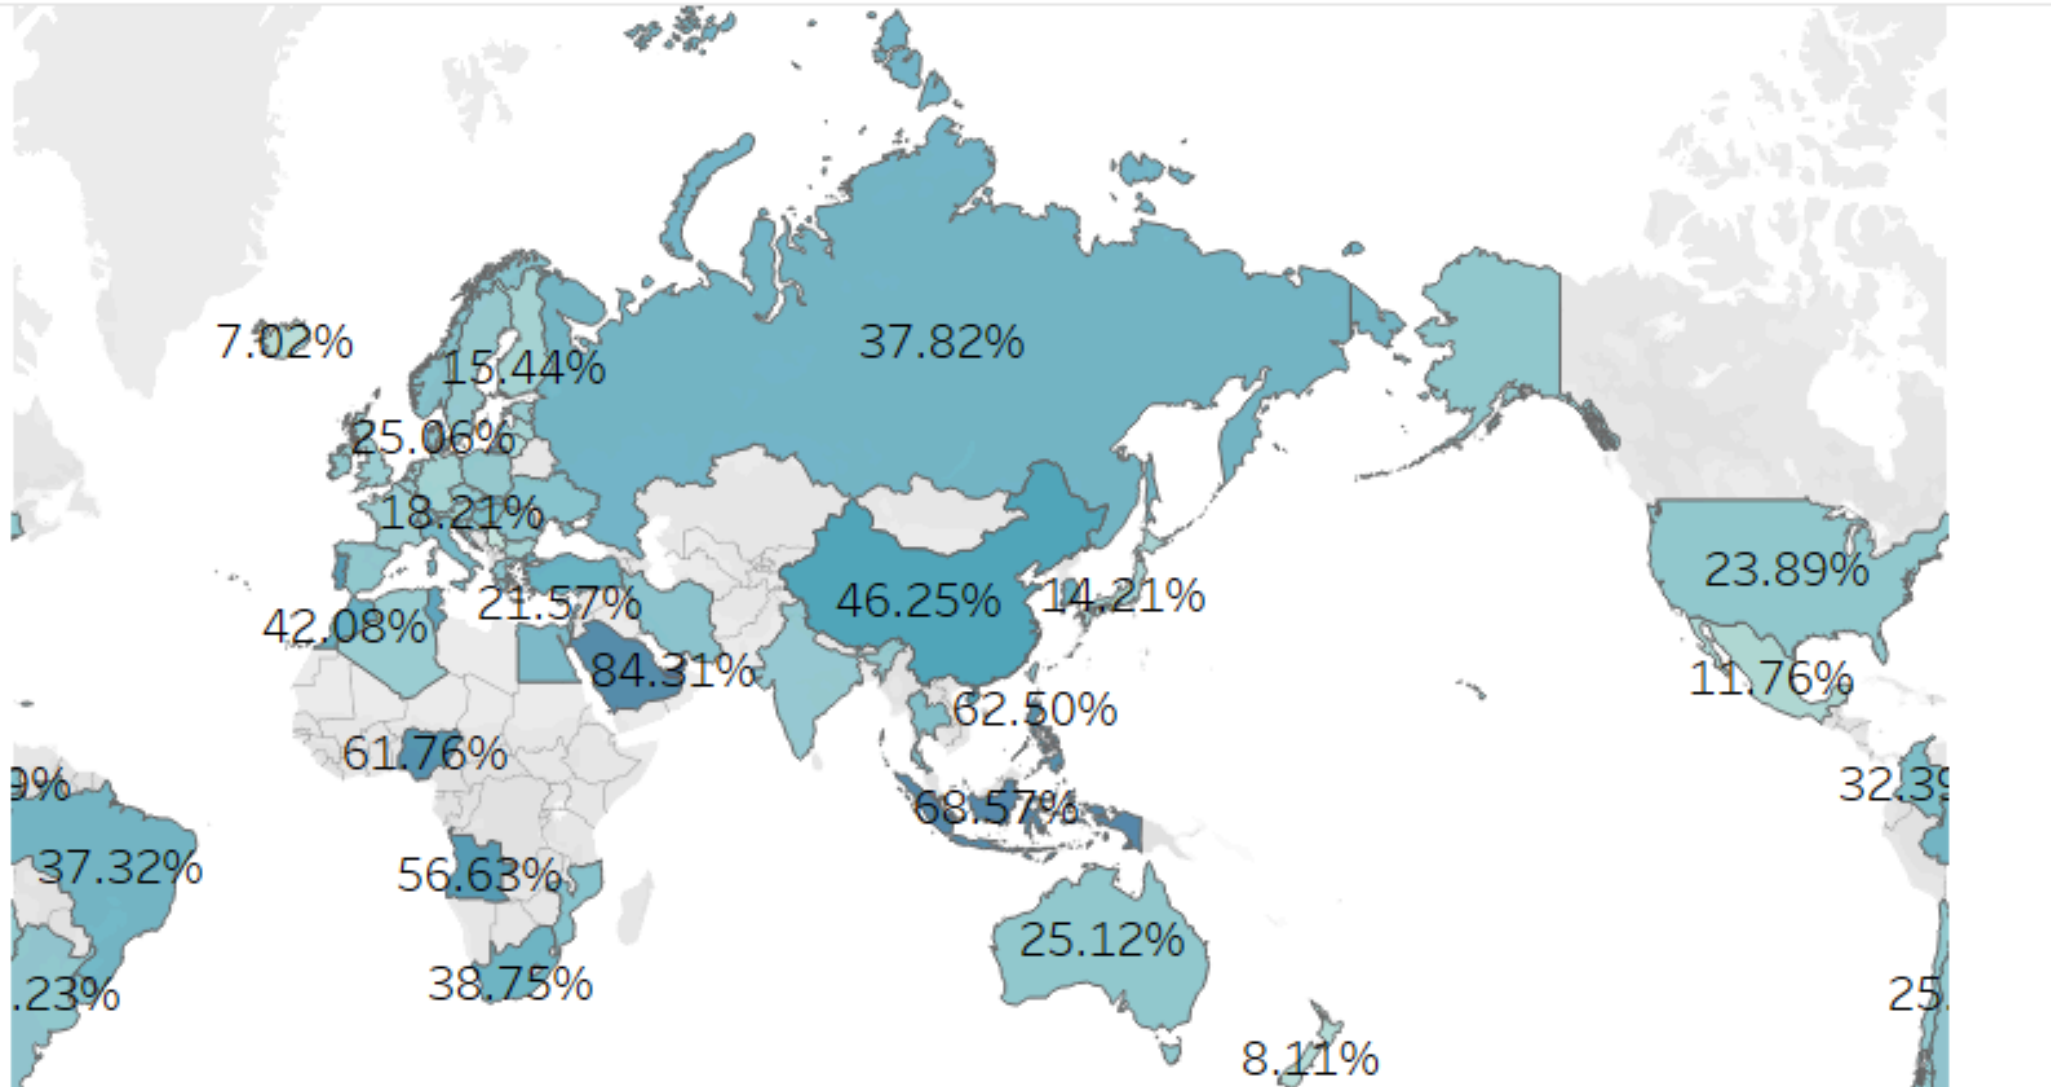
בנינו 9 דוחות אינטראקטיביים ב Tableau
לפי שאלות עסקיות שונות
להלן הדוחות :



דוח 1 - ניתוח שיעור ביטולים לפי מדינה

מטרת ניתוח זה היא לזהות מדינות עם שיעורי ביטולים גבוהים, במטרה להעריך סיכוני הזמנות ולבצע אופטימיזציה של תנאי ביטול ואסטרטגיות שיווק לפי אזור גיאוגרפי. הניתוח בוצע על מדינות עם למעלה מ-30 הזמנות בלבד, על מנת להבטיח מהימנות סטטיסטית.

שיעור ביטולים לפי מדינה (+30 הזמנות)




cancellation_rate

2.97% 84.31%

המדינות המובילות לפי שיעור ביטולים (הזמנות ≥ 30)

country ..=




0.0 0.1 0.2 0.3 0.4 0.5 0.6 0.7 0.8 0.9 1.0

cancellation_rate %

מדינות כמו איחוד האמירויות (84.3%), ערב הסעודית (68.7%) ואינדונזיה (68.5%) הציגו שיעורי ביטול חריגים הממצאים עשויים להעיד על צורך בהקשחת תנאי ביטול או התאמת מסרים שיווקיים לקהל המקומי. הנתונים מתבססים על מדינות עם יותר מ-30 הזמנות בלבד, כדי למנוע הטיות סטטיסטיות.

דוח 2 - ניתוח ביטולים לפי סוג לקוח וערוץ הפצה

שיעור ביטולים לפי פלח שוק



market_segment

- Groups
- Corporate
- Online TA
- Direct
- Offline T..
- Compleme..
- Aviation

distribution_channel

- TA/TO
- GDS
- Corporate
- Direct


תובנות עיקריות

- קבוצות מובילות בשיעור ביטול חריג של 61% - סיכון גבוה
- גם סוכנויות נסיעות מציגות ביטולים גבוהים (20% - 36%)
- Corporate ו Direct ערוצי ההפצה יציבים עם ביטולים נמוכים

המלצות עסקיות

1. לשקול תנאי ביטול מחמירים יותר לקבוצות וסוכנויות (כמו דרישת מקדמה או קיצור חלון הביטול)
2. למקד קמפיינים בערוצים יציבים יותר
3. לבדוק מגמות ביטול חוזרות ולהתאים אסטרטגיה בהתאם

שיעור ביטולים לפי ערוץ הפצה



דוח 3 - ניתוח התאמה בין סוג חדר מוזמן לסוג שהוקצה בפועל

סוג החדר : מוזמן ושהתקבל בפועל

reserved_room_type	assigned_room_type											
	A	B	C	D	E	F	G	H	I	K	L	P
A	73,598	1,123	1,447	7,548	1,156	417	186	94	215	210		
B	111	988		5	2	2	8			2		
C	5	2	883	6	4	2	10		10			
D	312	27	341	7,736	686	204	82	9	67	44		
E	15	3	8	22	5,923	404	100	4	40	16		
F	6	17		4	31	2,707	116	3	10	3		
G	5	2	2		4	14	2,041	7	15	4		
H				1			10	584	6			
L	1	1	1			1		1			1	
P												

הטבלה מציגה הצלבה בין סוגי החדרים שהוזמנו לבין אלו שהוקצו בפועל

תובנות עיקריות

- ברוב המקרים (73,598 הזמנות), לקוחות שהזמינו חדר מסוג A אכן קיבלו חדר מסוג A
- עם זאת, נצפה גם מספר גבוה של מקרים (7,548) שבהם לקוחות הזמינו חדר מסוג A אך קיבלו חדר מסוג D
- ייתכן שמדובר במדיניות פנימית של שדרוגים או מגבלות זמינות

המלצות עסקיות


- לבדוק האם הלקוחות קיבלו התראה על שינוי סוג החדר, והאם זה השפיע על שביעות רצון או על שיעורי ביטול
- לוודא שיש זמינות מספקת של חדרים מסוג A ובמקרה של שדרוג או שינוי - ליידע את הלקוח מראש
- לשקול חיזוק מערך התחזיות וההתאמות בין ביקוש להיצע לפי סוג חדר



דוח 4 - השפעת זמן מרגע ההזמנה על שיעור הביטולים

שיעור ביטולים לפי זמן מראש להזמנה

lead_time_range



תובנות עיקריות


- קיימת מגמה ברורה: ככל שזמן ההזמנה ארוך יותר מראש - כך עולה שיעור הביטול
- לקוחות שהזמינו בטווח של 0-30 ימים מראש ביטלו רק ב 18.5% מהמקרים
- לעומת זאת, הזמנות שבוצעו מעל שנה מראש (+366 ימים) בוטלו בשיעור גבוה מאוד של 67.6%.
- ייתכן שזמן ההמתנה הארוך מוביל לשינויים בנסיבות אצל הלקוח ולביטול ההזמנה

המלצות עסקיות

- לשקול מדיניות ביטול נוקשה יותר או תמחור שונה להזמנות שמבוצעות זמן רב מראש
- לבדוק אפשרות לשליחת תזכורות או הגברת המעורבות של הלקוח ככל שמתקרב מועד השהות - כדי לצמצם ביטולים

דוח 5 – ניתוח שיעור ביטולים לפי סוג ארוחה


השפעת סוג הארוחה על שיעור הביטולים



טבלת שיעור הביטול לפי סוג ארוחה

טבלת מספר הזמנות לפי סוג ארוחה

meal (..) =		meal (..	
FB	0.5990	BB	92,310
BB	0.3738	FB	798
SC	0.3724	HB	14,463
HB	0.3446	SC	10,650
Undefi..	0.2447	Undefi..	1,169



תובנות עיקריות


- סוג הארוחה FB (Full Board) מציג שיעור ביטולים גבוה במיוחד של 59.9%.
- למרות מספר ההזמנות הנמוך (798 בלבד), שיעור הביטולים חריג.
- לעומת זאת, סוג BB (Bed & Breakfast) מופיע ביותר מ- 92,000 הזמנות, עם שיעור ביטולים ממוצע של כ-37.3%.
- קטגוריית Undefined מציגה את שיעור הביטולים הנמוך ביותר - 24.5%.

המלצות עסקיות

- לבחון מחדש את תנאי ההזמנה והמחיר של חבילת FB בשל שיעורי ביטול גבוהים.
- לבדוק האם יש הצדקה כלכלית לצמצם את חבילת FB ולהשקיע יותר בחבילות פופולריות כמו BB או SC.
- למקד את השיווק של FB ללקוחות עם כוונת הזמנה גבוהה בלבד (ולא לקהל כללי).

דוח 6 - ניתוח שיעור ביטולים לפי סוג פיקדון

ניתוח שיעור ביטולים לפי סוג פיקדון



טבלת שיעור הביטולים ומספר ההזמנות לפי סוג פיקדון

deposit_type	
No Deposit	104,641
Non Refund	14,587
Refundable	162

תובנות עיקריות

- שיעור ביטולים גבוה במיוחד עבור סוג ההזמנה Non Refund - כ 99% וכמות גדולה של הזמנות 14,587 .
- ייתכן שהלקוחות לא הבינו את תנאי הפיקדון או לא שמו לב אליהם.
- קטגוריית No Deposit היא הנפוצה ביותר (104,641 הזמנות) ומציגה שיעור ביטול נמוך יחסית.
- קטגוריית Refundable כמעט לא קיימת (162 מקרים), אך מציגה שיעור ביטול נמוך במיוחד – כ-22%.


המלצות עסקיות

1. לבחון מחדש את מדיניות Non Refund - ייתכן צורך בשיפור הצגת התנאים או הוספת אישור כפול בעת ההזמנה.
2. לשקול הרחבת אפשרות ההזמנה ללא פיקדון (No Deposit).
3. למקד את חבילת Non Refund רק ללקוחות עם כוונת הזמנה גבוהה, כדי להפחית את שיעור הביטולים.

דוח 7 - שיעור ביטולים לפי לקוח חוזר

גרף לשיעור ביטולים לפי לקוח חוזר

is_repeated_guest (Dim_Customer.csv)



cancellation_rate



14.49% 37.79%

טבלה לשיעור ביטולים לפי לקוח חוזר

is_repeated_guest ..

False	37.79%
True	14.49%

תובנות עיקריות


- שיעור הביטולים בקרב לקוחות חוזרים נמוך משמעותית - כ-14.5% בלבד, לעומת כ-37.8% בקרב לקוחות שאינם חוזרים.
- נתון זה עשוי להעיד על נאמנות גבוהה יותר של לקוחות חוזרים, היכרות עם תהליך ההזמנה או תחושת ביטחון גבוהה יותר בשירות מצד הלקוח.

המלצות עסקיות

- מומלץ להשקיע בלקוחות חוזרים - דרך מועדוני לקוחות, קמפיינים ממוקדים, הטבות ייחודיות והצעות מותאמות אישית.
- ניתן לבחון את פרופיל הלקוחות החוזרים כדי להבין מה מאפיין אותם, ולנסות לשמר או להרחיב קהל כזה.
- לשקול תמריצים ראשוניים ללקוחות חדשים - כדי להגביר את הסיכוי שיחזרו שוב ויצמצמו ביטולים בעתיד.

דוח 8: ניתוח טופ 10 סוכנים לפי שיעור ביטולים

גרף לשיעור ביטולים לפי סוכן הזמנה מוביל




טבלת שיעור ביטולים לפי סוכן

agent_id	cancellation_rate
1	73.43%
9	41.50%
240	39.39%
6	31.16%
No agent	24.66%
14	17.91%
250	17.87%
241	13.71%
7	13.39%
28	6.60%

טבלת מספר הזמנות לפי סוכן

agent_id	Count of Dim_C..
9	31,961
No agent	16,340
240	13,922
1	7,191
14	3,640
7	3,539
6	3,290
250	2,870
241	1,721
28	1,666



תובנות עיקריות


- סוכן מספר 1 מציג שיעור ביטולים חריג של כ **73.4%**.
- גם סוכנים 9 ו-240 בולטים בשיעורי ביטול גבוהים (מעל 39%).
- לעומתם, סוכן 28 מציג שיעור ביטול נמוך מאוד של כ **6.6%**.
- חשוב לבחון את שיעור הביטול ביחס להיקף ההזמנות, כדי לא לפספס סוכנים עם השפעה משמעותית.

המלצות עסקיות

- לבחון לעומק את פעילותו של סוכן 1 (שיעור הביטול הגבוה ביותר) וכן את סוכן 9, אשר ביצע את מספר ההזמנות הגבוה ביותר (**31,961**) עם שיעור ביטול גבוה.
- ללמוד מדפוס הפעולה של סוכן 28 - שמציג שיעור ביטול נמוך במיוחד - ולבחון דרכים לעודד התנהגות דומה גם בקרב סוכנים אחרים.


דוח 9: ממוצע הכנסה לפי שוק

גרף ממוצע הכנסה ללילה לפי סוג שוק



טבלת ממוצע הכנסה ללילה לפי סוג שוק

market_seg..	
Online TA	117.2
Direct	115.4
Aviation	100.1
Offline TA/TO	87.4
Groups	79.5
Corporate	69.4
Undefined	15.0
Complementary	2.9



Filters:

distribution_channel

(All)

hotel (Dim_Hotel.csv)

(All)

arrival_date_month

(All)

תובנות עיקריות

- סוגי השוק הרווחיים ביותר הם: Online TA (117.2) ו Direct (115.4)
- סוגי השוק הפחות רווחיים הם: Complementary (2.9) ו Undefined (15)
- ניכר פער משמעותי בהכנסה ללילה בין פלחי השוק, מה שמעיד על פוטנציאל לשיפור הרווחיות באמצעות פילוח שוק חכם ואסטרטגי.

המלצות עסקיות


- להשקיע בשיווק ומבצעים עבור סוגי השוק הרווחיים (Online TA, Direct).
- לשקול להגביל או לשנות מדיניות ההזמנות מסוג Complimentary או Undefined כדי לצמצם הפסדים.

הפילטרים בדוח מאפשרים לבחון את ממוצע ההכנסה ללילה לפי:

- ערוץ הפצה (Distribution Channel)
 - סוג מלון (Hotel Type)
 - חודש הזמנה (Arrival Date Month)
- כך ניתן לזהות הבדלים בין תקופות, ערוצים וסוגי לקוחות, ולהתאים את האסטרטגיה בהתאם למקורות הרווח המרכזיים.

דוח 10: השוואה חודשית בין סך ההזמנות לביטולים


גרף סך כל ההזמנות והזמנות שבוטלו לאורך זמן



תובנות עיקריות

- שיעור הביטולים ירד מ-55.7% (2015) ל-9.3% (סוף 2017) – שיפור מובהק.
- שיאי ביטול נצפו במחצית השנייה של 2015 ו-2017.
- ייתכן שינויים במדיניות או שיפור בשירות תרמו לירידה בסוף התקופה.


גרף שיעור הביטולים מתוך ההזמנות – לפי חודש



המלצות עסקיות

1. לנתח לעומק את תקופות שיא הביטול (2015, 2017) ולזהות גורמים חוזרים.
2. לשמר אסטרטגיות מצליחות מסוף 2017 ולהרחיבן לתקופות נוספות.
3. לשקול הטבות או תמריצים למניעת ביטול – בפרט בתקופות רגישות.

הגרף התחתון:



total bookings

1 5,742

canceled bookings

0 2,616

הגרף העליון:

סיכום קצר – דוחות ותובנות מרכזיות

01



תובנות מרכזיות מהדוחות :

- איתרנו מאפיינים ברורים ללקוחות עם סיכון גבוה לביטול (לקוחות חדשים, הזמנות Non Refund, קבוצות וסוכנים מסוימים).
- זיהינו פלחי שוק רווחיים משמעותית (Direct, Online TA), שכדאי למלון להתמקד בהם.

02



המלצות כלליות:

- להקשיח תנאי ביטול בקבוצות ובפלחי שוק בעייתיים.
- להשקיע יותר בלקוחות חוזרים ובערוצים הרווחיים ביותר.

כריית מידע – כלים מתקדמים להבנת הלקוחות



לאחר שביצענו ניתוחים עסקיים באמצעות Tableau, עברנו לשלב מתקדם של כריית מידע (Data Mining) במטרה להבין לעומק את התנהגות הלקוחות ולחזות את הסיכוי לביטול.

בשלב זה יישמנו שני סוגים של ניתוחים:

1. מודלים מונחי מטרה - לחיזוי האם הזמנה תבוטל
2. Clustering (קלאסטרינג) - לזיהוי קבוצות לקוחות עם דפוסים דומים

כל המודלים נבנו על סמך אותם מאפיינים שזיהינו כדומיננטיים בדוחות ה-BI.



חיזוי ביטול הזמנה Logistic Regression

מטרה :

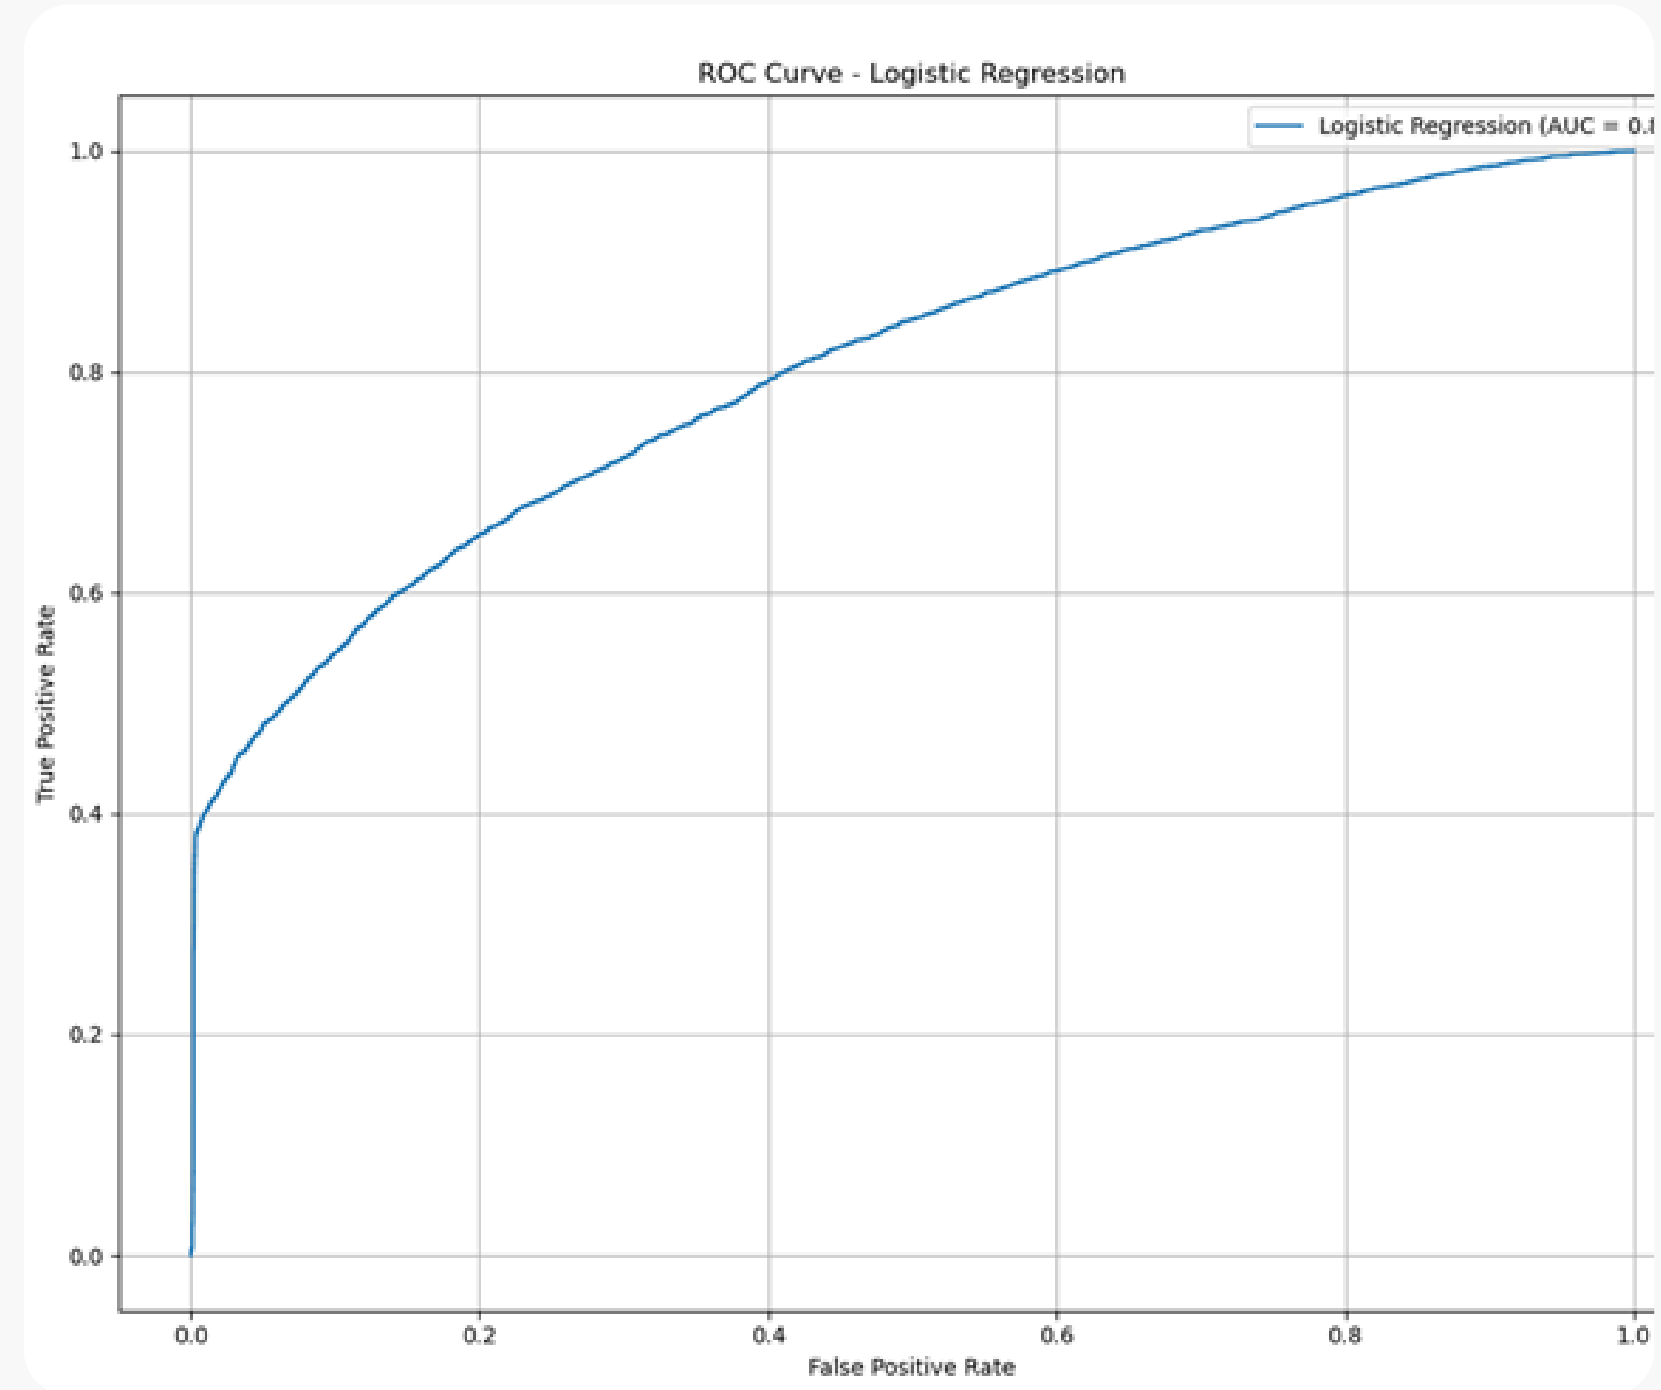
לבנות מודל Logistic Regression לחיזוי האם ההזמנה תבוטל (is_canceled) על בסיס מאפייני ההזמנה

שלבי העבודה :

- ניקוי והכנת נתונים
- המרה לקטגוריות עם LabelEncoder
- חלוקת הנתונים ל-Train/Test (80/20)
- בניית המודל והערכתו עם Accuracy, Precision, Recall, F1
- הפקת עקומת ROC ו-AUC

תוצאות :

```
Accuracy: 0.7737
Precision: 0.8938
Recall: 0.4512
F1 Score: 0.5997
```




השוואת מודלים מונחי מטרה: חיזוי סטטוס ההזמנה

מטרה :

לבנות מודל Logistic Regression לחיזוי האם ההזמנה תבוטל (is_canceled) על בסיס מאפייני ההזמנה

שלבי העבודה :

- ניקוי והכנת נתונים
- המרה לקטגוריות עם LabelEncoder
- חלוקת הנתונים ל-Train/Test (80/20)
- בניית המודל והערכתו עם Accuracy, Precision, Recall, F1
- הפקת גרף ROC למודל Decision Tree
- ניתוח חשיבות מאפיינים



השוואת מודלים מונחי מטרה:

חיזוי סטטוס ההזמנה (המשך)

המאפיינים המשפיעים ביותר לפי Decision Tree :

- 0.673 - deposit_type (סוג הפקדון)
- 0.104 - lead_time (זמן הזמנה מראש)
- 0.090 - previous_cancellations (ביטולים קודמים)
- 0.050 - adr (מחיר ללילה)
- 0.044 - total_of_special_requests (בקשות מיוחדות)

מודלים אלו מאפשרים להבין אילו לקוחות עלולים לבטל מראש ויכולים לשמש כבסיס למדיניות מניעה חכמה


ביצועי המודלים :

מודל	Accuracy	Precision	Recall	F1 Score
Decision Tree	76.75%	82.80%	76.75%	73.20%
Random Forest	82.85%	82.51%	82.85%	82.42%
KNN	76.78%	76.40%	76.78%	76.19%

תובנות והמלצות מהמודלים :

- מודל Random Forest נתן את התוצאה הכוללת הטובה ביותר עם דיוק (Accuracy) ו-Recall גבוהים במיוחד.
- מאפיין סוג הפיקדון (deposit_type) השפיע בצורה מובהקת על כל המודלים.
- Recall גבוה חשוב במיוחד כשמנסים לחזות ביטולים כדי למנוע הפסדים - ולכן Random Forest עדיף במקרה הזה.
- המאפיינים שנבחרו משקפים את התרומה של מדיניות ההזמנה וההתנהגות ההיסטורית של הלקוח על סטטוס ההזמנה.

פילוח לקוחות באמצעות K-Means



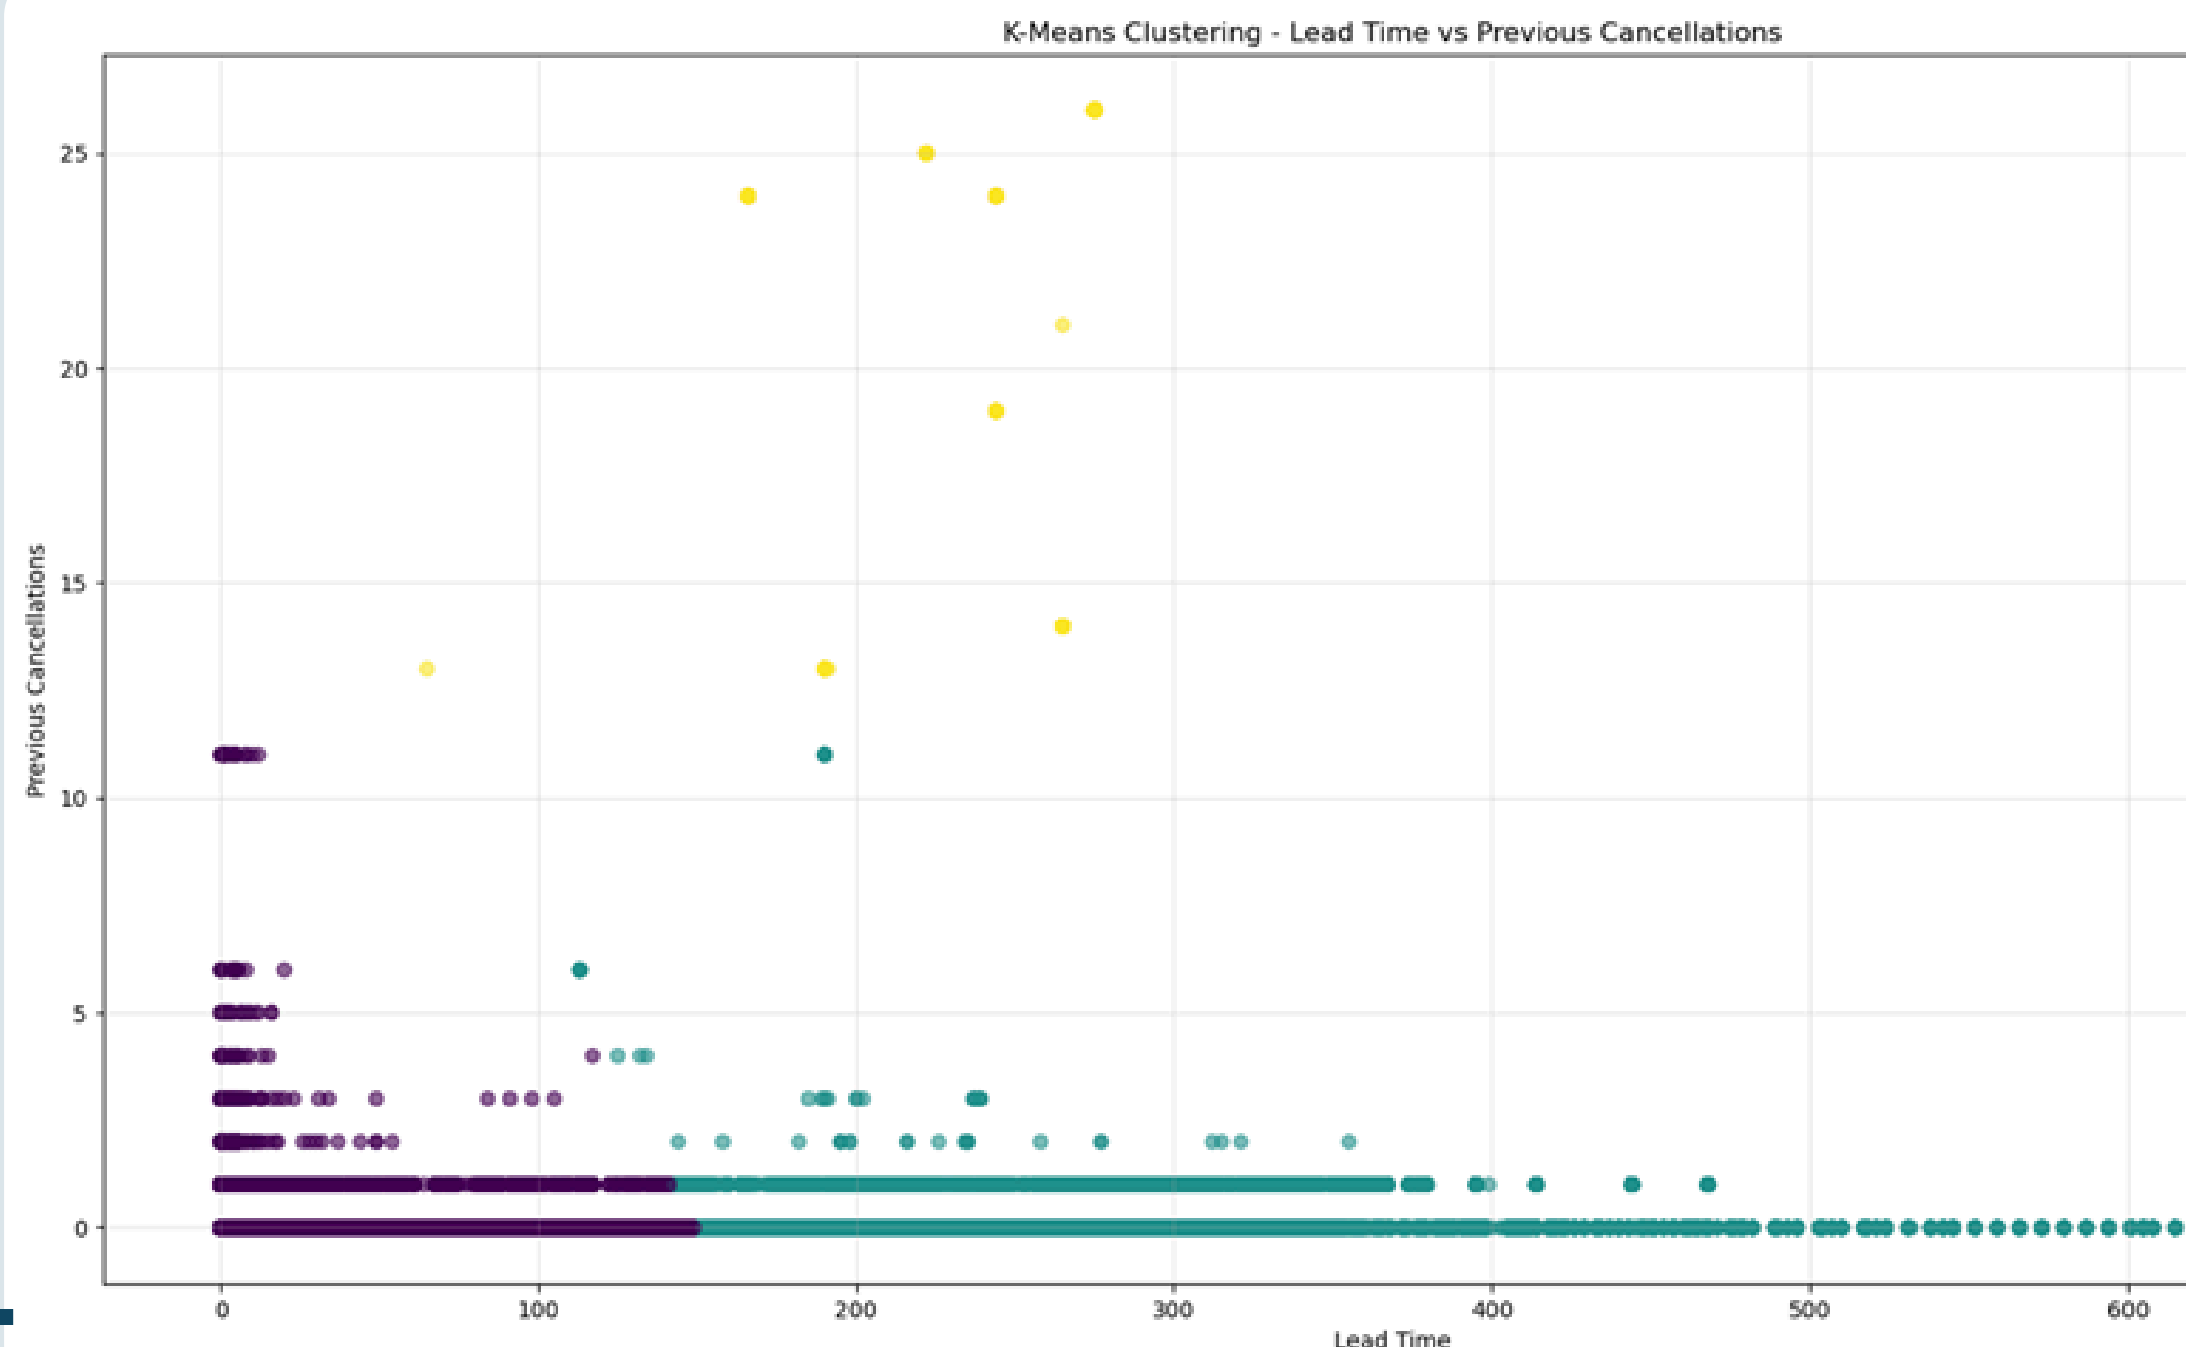
מטרה :

- לזהות קבוצות לקוחות שונות לפי מאפייני התנהגות והזמנה.
- להבין אילו סוגי לקוחות קיימים במלון לצורך שיווק ממוקד או שירות מותאם אישית.

שלבי העבודה :

- בחירת מאפיינים רלוונטיים (לדוגמה: lead_time, adr, deposit_type)
- נרמול הנתונים עם StandardScaler.
- בחירת מספר הקלאסטרים (k)

הצגת הקלאסטרים על פי ביטולים קודמים מול זמן הזמנה מראש

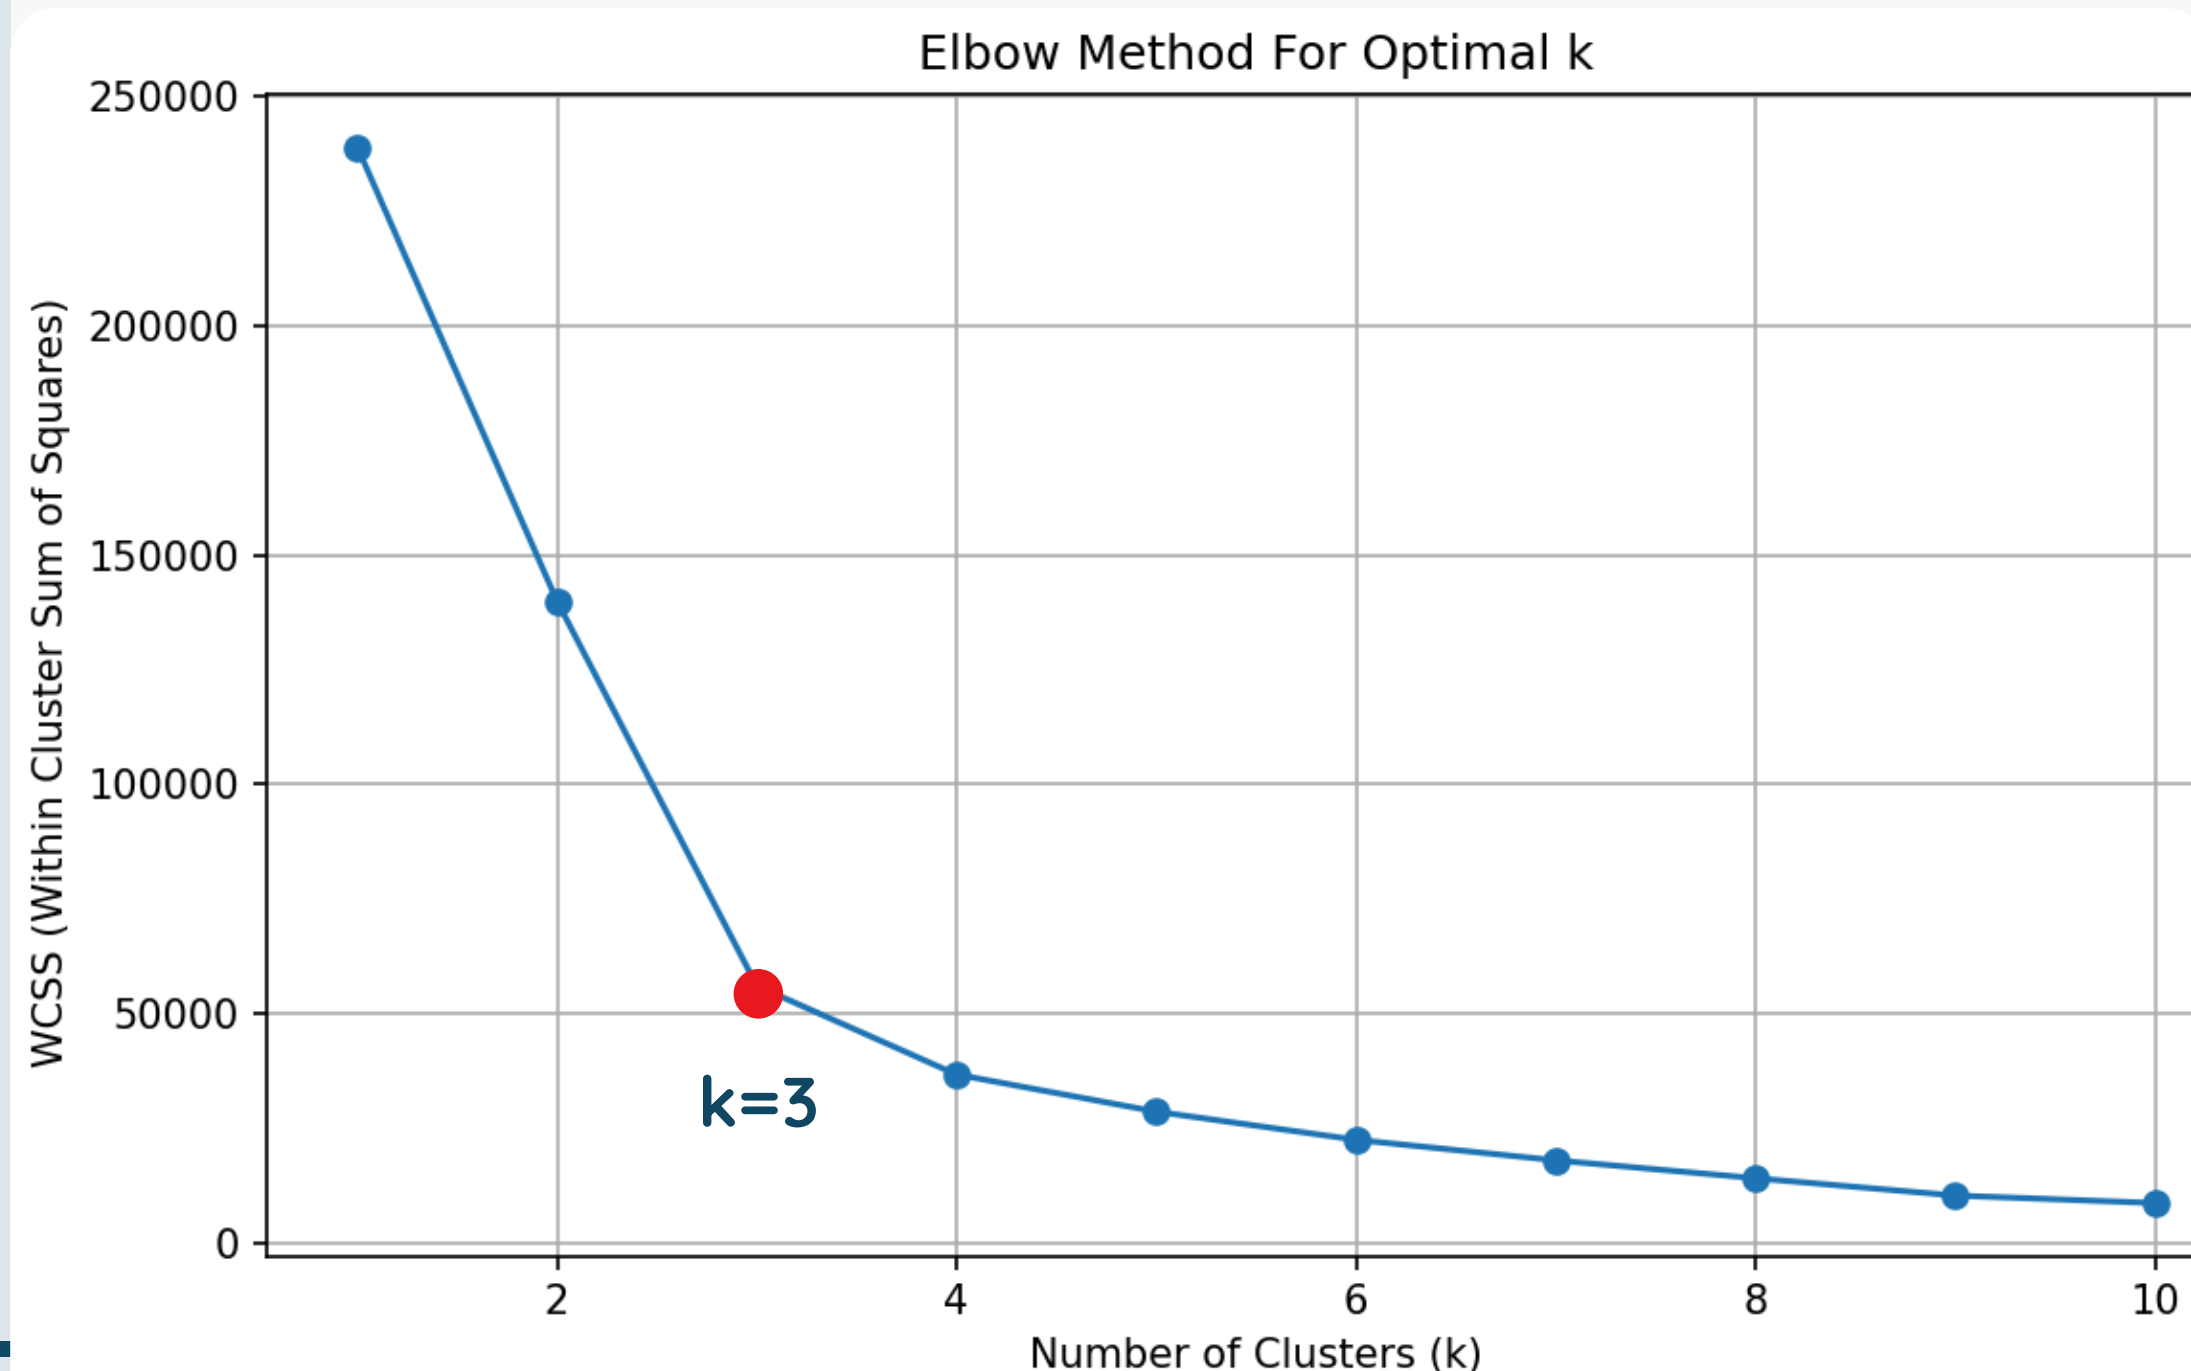


בחירת ה- k האופטימלי עבור K-Means

בחירת מספר האשכולות האופטימלי (k) בשיטת Elbow

למה בחרנו ב- $k=3$?

- בחרנו ב- $k=3$ כי זו נקודת השבירה בה שיפור WCSS מתחיל להתמתן.
 - לכן זו נקודת ה-Elbow – והקלאסטרिंग הכי הגיוני על בסיס הנתונים
- בנקודה הזו – צריך לבחור חכם. זה הכיוון הנכון.



תובנות מה Clustering



נקודות עיקריות :

- זיהינו 3 קבוצות מרכזיות של לקוחות לפי מאפייני הזמנה והתנהגות.
- לקוחות עם זמן הזמנה ארוך והרבה ביטולים קודמים מזהים כבעלי סיכון גבוה לביטול.
- לקוחות עם זמן הזמנה קצר וכמעט ללא ביטולים - מזהים כקהל יציב ונאמן.
- ניתן להשתמש בפילוח הזה לשיווק ממוקד, הנחות מותאמות, או התרעות לסיכוני ביטול.

תוצאות K-Means Clustering :

ממוצע Previous Cancellations	ממוצע Lead Time	מספר לקוחות בקבוצה	אשכול
0.1	40.2	23,384	0
1.3	82.5	10,932	1
8.9	69.8	1,250	2

- אשכול 0 (סגול) - לקוחות יציבים עם ביטולים נמוכים וזמן המתנה קצר.
- אשכול 1 (טורקיז) - לקוחות עם ביטולים מתונים וזמן הזמנה בינוני.
- אשכול 2 (צהוב) - לקוחות עם ביטולים רבים וסיכון רב.
- (הצבעים מתייחסים לגרף הקלאסטרינג בשקף הקודם).

איך היינו משלבים *Big Data* בפרויקט שלנו?



Big Data מתייחס לניתוח כמויות גדולות של מידע ממקורות מגוונים, במהירות ובזמן אמת.

אם היינו משלבים מקורות מידע כמו התנהגות באתר, חיפושי משתמשים, חוות דעת לקוחות ומידע תחרותי – היינו מסוגלים לנבא ביטולים מראש ולהציע התערבות מותאמת.

היינו משתמשים בטכנולוגיות כמו Kafka ו-Apache Spark לעיבוד בזמן אמת, ומודלים מתקדמים כמו XGBoost לחיזוי מדויק ולשפר את קבלת ההחלטות באופן משמעותי, בזמן אמת – ברמה שמונעת הפסדים בפועל.



מה עשינו?	מה היינו עושים עם Big Data?
דאטה מובנה בלבד	שילוב דאטה חיצוני והתנהגותי
ניתוח בדיעבד	ניתוח בזמן אמת
חיזוי כללי	חיזוי מותאם אישית
קלאסטרינג בסיסי	קלאסטרינג לפי דפוסי שימוש



תודה רבה !

